

RÉPUBLIQUE DU CAMEROUN
Paix – Travail – Patrie

INF232

Analyse de Données pour une Plateforme de Mise en Relation Freelance / Client

RAPPORT DE TRAVAUX PRATIQUES — GROUPE 14

Membres du groupe

Nom et Prénom	Matricule
Lambo Lekoubou Dimitri	23V2154
Kuichouo Leopold Stanislas	24G2363
Meli Tanga Jeeps Parvel	23V2413
Nkonzap Ariane	24F2875
Yonkoua Yann Luca	23U2699
Tedom Tafotsi Dimitri Wilfried	23V2180
Mamboune Nchourupouo Basma	24F2976
Ngono Danielle Stéphanie Estelle	24G2232
Tekeng Kamwele Junior Cambell	23U2686
Nguefah Zeutcha Carol Junior	23U2597

Année académique 2025 – 2026
Date de remise : 5 juillet 2026

Sommaire

Introduction générale.....	3
1. Justification de la graine (seed) et du hachage.....	4
2. Justification de la modélisation des données.....	5
3. Question 1 — Analyse descriptive de la performance.....	6
4. Question 2 — Corrélation et régression linéaire (TJM / Performance).....	7
5. Question 3 — Clustering K-Means.....	8
6. Question 4 — Classification supervisée (Régression logistique).....	9
Conclusion générale.....	10

Introduction générale

Ce rapport présente les travaux réalisés par le Groupe 14 dans le cadre du cours INF232. Le projet porte sur l'analyse de données synthétiques simulant une plateforme numérique de mise en relation entre freelances et clients (Thème B). L'objectif est de mettre en pratique un ensemble de méthodes statistiques et de Data Science — analyse descriptive, corrélation, régression linéaire, clustering non supervisé (K-Means) et classification supervisée (régression logistique) — afin d'accompagner la fondatrice de la plateforme dans ses décisions stratégiques et commerciales.

Le jeu de données a été généré de manière déterministe à partir d'une graine numérique (seed) calculée par un algorithme de hachage polynomial appliqué au nom du chef de groupe, garantissant la reproductibilité totale des résultats présentés. L'échantillon comporte $N = 250$ freelances caractérisés par trois variables : le Tarif Journalier Moyen (TJM), le Score de Performance et le Statut commercial (Premium / Standard).

Ce document est structuré en six grandes parties correspondant à la répartition des tâches entre les membres du groupe : la justification de la graine et de l'algorithme de hachage, la justification de la modélisation des données, puis les quatre questions d'analyse (descriptive, régression, clustering, classification). Chaque partie présente la méthodologie retenue, les résultats numériques obtenus, une synthèse orientée décision, ainsi qu'une analyse critique des limites du modèle utilisé.

1. Justification de la graine (seed) et de l'algorithme de hachage

Auteur : TEDOM TAFOTSI DIMITRI WILFRIED (Membre 1 — Chef de Projet)

1.1 Informations du groupe et nom traité

Conformément au format normalisé exigé (sans accents, sans espaces, en majuscules), deux options ont été envisagées :

- Format « [Prénoms][Nom] » (recommandé, conforme à l'exemple du sujet) :
DIMITRIWILFRIEDTEDOMTAFOTSI
- Format alternatif « [Nom][Prénoms] » : TEDOMTAFOTSIDIMITRIWILFRIED

1.2 Algorithme de hachage choisi : hachage polynomial (Rolling Hash)

Afin de disposer d'une fonction native, robuste et déterministe, sans dépendance externe, le groupe a implémenté un hachage polynomial. La graine numérique $H(S)$ est calculée à partir de la chaîne normalisée S de longueur n , selon la formule :

$$H(S) = (\sum ord(S[i]) \cdot p^{(n-1-i)}) \bmod m, \quad \text{avec } i = 0 \dots n-1$$

- S : chaîne de caractères normalisée de longueur n ;
- $ord(S[i])$: valeur ASCII du caractère à la position i ;
- $p = 31$: base de multiplication (nombre premier) ;
- $m = 2^{31} - 1 = 2\,147\,483\,647$: modulo, nombre premier de Mersenne M31.

Justification mathématique et logique de la conception

- Garantie de déterminisme : la fonction native `hash()` de Python est proscrite car non déterministe d'une session à l'autre (randomisation introduite depuis Python 3.3). La formule polynomiale ne dépend que des caractères et de leur ordre, assurant une graine strictement identique à chaque exécution.
- Sensibilité à l'ordre des caractères : une simple somme des valeurs ASCII provoquerait des collisions entre anagrammes ; le coefficient $p^{(n-1-i)}$ pondère chaque lettre selon sa position, éliminant ce risque.
- Choix de $p = 31$: nombre premier impair classique (utilisé notamment dans `String.hashCode()` en Java), assurant une distribution uniforme des valeurs hachées.
- Choix de $m = 2^{31} - 1$: nombre premier de Mersenne garantissant un entier positif représentable sur 31 bits, universellement compatible avec les générateurs pseudo-aléatoires (dont `random.seed()` de Python).

1.3 Valeurs de graine obtenues

Format	Chaîne traitée	Graine numérique
Option A (retenue)	DIMITRIWILFRIEDTEDOMTAFOTSI	853 155 114
Option B (alternative)	TEDOMTAFOTSIDIMITRIWILFRIED	354 927 805

La graine retenue pour l'ensemble des analyses du groupe est 853 155 114 (Option A), conforme à l'exemple illustratif du sujet.

2. Justification de la modélisation des données

Auteur : MAMBOUNE NCHOUROUPOUO BASMA (Membre 2 — Architecte de Données)

2.1 Définition et justification des variables

A. Le Tarif Journalier Moyen (TJM)

Bornes : 100 € à 950 €. Le TJM reflète la réalité économique du marché du freelancing : 100 € correspond à des profils très juniors ou à des tâches à faible valeur ajoutée, tandis que 950 € correspond à des experts hautement qualifiés (architectes cloud, consultants en cybersécurité, data scientists seniors). Nature de la variable : quantitative continue.

B. Le Score de Performance

Bornes : 0 à 100. Ce score agrège plusieurs indicateurs de satisfaction client (respect des délais, qualité du travail, communication) : 0 représente un échec critique, 100 une mission parfaite. Nature de la variable : quantitative discrète (ou continue selon l'arrondi).

C. L'étiquette (statut du freelance)

Valeurs : Premium / Standard. Cette variable permet à la plateforme de segmenter son offre : le statut Premium distingue les meilleurs profils, combinant souvent un TJM élevé et un excellent score de performance, afin de les valoriser auprès des clients exigeants. Nature de la variable : qualitative nominale binaire.

2.2 Justification de la taille de l'échantillon (N = 250)

- Théorème central limite : un échantillon est jugé suffisant pour appliquer la loi des grands nombres et la loi normale dès que $N > 30$. Avec $N = 250$, ce seuil est largement dépassé, garantissant la robustesse des tests et modèles (notamment la régression linéaire).
- Stabilité des modèles de Data Science : pour le clustering K-Means et la régression logistique, 250 lignes offrent assez de matière pour distinguer des groupes sans risquer un surapprentissage du modèle.
- Performance applicative : cette taille est idéale pour un traitement instantané en Python et un affichage fluide dans l'interface interactive Streamlit du groupe.

3. Question 1 — Analyse descriptive de la performance

Auteur : NGONO DANIELLE STÉPHANIE ESTELLE (Membre 4)

3.1 Méthodes mobilisées et justification

L'analyse porte sur une étude univariée de la variable `score_performance`, réalisée avec Python (pandas, matplotlib, seaborn). Les indicateurs calculés sont la moyenne, la médiane, la variance et l'écart-type. La détection des valeurs atypiques (outliers) repose sur la méthode de l'IQR (Interquartile Range) et sur la boîte à moustaches de Tukey, permettant d'identifier les freelances dont la performance est statistiquement atypique.

3.2 Résultats et visualisation

- Moyenne de la performance : valeur centrale de l'échantillon.
- Médiane de la performance : sépare les 50 % de freelances les mieux notés du reste.
- Variance : dispersion des scores autour de la moyenne.
- Écart-type : mesure de la volatilité de la performance dans l'échantillon.
- Outliers IQR : freelances situés en dehors de l'intervalle $[Q1 - 1,5 \times IQR ; Q3 + 1,5 \times IQR]$.




Figure 1 — Boîte à moustaches (boxplot) de la variable `score_performance`

3.3 Synthèse à destination du comité d'investisseurs

L'analyse de la performance montre la qualité générale du fichier de freelances. Une moyenne élevée indique que la majorité des freelances affichent des scores performants, tandis que la médiane conforte cette observation en limitant l'influence des valeurs extrêmes. Pour les investisseurs, la base de talents apparaît globalement solide et la plateforme peut raisonnablement proposer des freelances compétents à ses clients.

La présence d'outliers, identifiés via la boîte à moustaches, est également utile : elle permet de repérer les profils très en dessous ou très au-dessus de la tendance générale. Ces freelances peuvent être traités différemment dans les stratégies commerciales — les meilleurs mis en avant dans une offre Premium, les moins performants nécessitant un accompagnement ou une vérification de qualité.

Point clé pour les investisseurs

- Base de talents globalement solide (moyenne et médiane cohérentes).
- Les outliers identifiés permettent une segmentation commerciale fine (Premium vs. accompagnement).

3.4 Analyse critique et limites

Cette analyse porte uniquement sur le score_performance et ne tient pas compte des autres dimensions du modèle économique (TJM, expérience client, domaine d'expertise, régularité des missions). Un score élevé peut masquer des disparités de spécialisation ou de capacité à livrer des projets complexes.

La méthode IQR identifie les valeurs atypiques sans distinguer les outliers pertinents des anomalies liées à des erreurs de saisie. Enfin, l'échantillon étant synthétique et déterministe, il reflète davantage la structure choisie par le groupe que la variabilité réelle d'un marché freelance : les résultats restent illustratifs et une validation sur des données opérationnelles réelles demeure nécessaire.

4. Question 2 — Corrélation et régression linéaire (TJM / Performance)

Auteur : KUICHOUO LEOPOLD STANISLAS (Membre 5 — Analyste Statistique)

4.1 Choix méthodologiques et justifications

L'objectif est d'étudier la relation entre le Tarif Journalier Moyen (variable X) et le score de performance historique des freelances (variable Y). L'analyse se déroule en deux étapes : le calcul des coefficients de corrélation de Pearson (r) et de Spearman (ρ), puis une régression linéaire simple par la méthode des moindres carrés ordinaires (MCO), afin d'estimer si la performance d'un nouveau freelance peut être raisonnablement anticipée à partir de son seul TJM.

4.2 Résultats numériques

Jeu de données généré à partir de la graine 853 155 114.

Indicateur	Valeur	Interprétation
Corrélation de Pearson (r)	0,2771	Corrélation positive faible
Corrélation de Spearman (ρ)	0,3276	Corrélation monotone faible à modérée
Coefficient de détermination (R^2)	0,0768 (7,68 %)	Faible pouvoir explicatif du TJM

Équation de la droite d'ajustement obtenue : $\text{Performance} = 0,0390 \times \text{TJM} + 38,0724$.

Concrètement, chaque augmentation de 100 € du TJM se traduit par une hausse moyenne estimée de 3,9 points du score de performance. La différence entre Pearson et Spearman s'explique par la présence de valeurs atypiques injectées dans le jeu de données, qui affaiblissent la relation strictement linéaire.




Figure 2 — Nuage de points TJM / Performance et droite de régression linéaire

4.3 Synthèse pour la fondatrice

L'analyse démontre l'existence d'une tendance positive légère : en moyenne, les freelances facturant des tarifs plus élevés affichent des scores de performance légèrement meilleurs. Sur le plan opérationnel, il est cependant fortement déconseillé de se baser uniquement sur le TJM d'un nouveau freelance pour prédire sa performance future.

Exemple : pour un freelance s'inscrivant avec un TJM de 500 €, la performance théorique estimée est de 57,6/100 ($0,0390 \times 500 + 38,07$). En réalité, les observations montrent une dispersion extrême — des freelances à 500 € de TJM affichent des scores réels allant de 15/100 à 90/100. Le TJM n'est donc pas, à lui seul, un signal d'évaluation fiable.

Risques identifiés

- Pouvoir explicatif très faible ($R^2 = 7,68 \%$) : 92,3 % de la variabilité de la performance reste inexpliquée.
- Sensibilité aux valeurs aberrantes injectées volontairement dans le jeu de données.
- Absence de causalité : le TJM reflète un positionnement tarifaire, non une compétence intrinsèque.

5. Question 3 — Clustering K-Means

Auteur : Membre 6 — Analyste Data Science

5.1 Méthodologie

Le clustering a été réalisé sur les deux variables numériques disponibles (TJM et score de performance), sans utiliser la colonne « statut » (Premium/Standard), afin de laisser l'algorithme découvrir une structure de groupes de manière non supervisée.

Les variables ont été standardisées (moyenne 0, écart-type 1) avant l'application du K-Means, car le TJM (échelle ~100–950 €) et le score de performance (échelle 0–100) n'ont ni la même unité ni la même variance : sans standardisation, le TJM aurait dominé artificiellement le calcul des distances euclidiennes.

5.2 Choix du nombre de clusters K

Deux méthodes complémentaires ont permis de justifier le choix de K :

- Méthode du coude (Elbow) : observation de la décroissance de l'inertie intra-cluster en fonction de K, jusqu'au point où l'ajout d'un cluster supplémentaire n'apporte plus de gain significatif.
- Score de silhouette : mesure de la qualité de séparation des clusters (proche de 1 = clusters bien séparés, proche de 0 = clusters qui se chevauchent).

K retenu : 2 (score de silhouette = 0,366), valeur maximisant le score de silhouette sur la plage testée (K = 2 à 8).

5.3 Caractérisation des groupes

Cluster	Effectif	TJM moyen	Performance moyenne
Cluster 0	118	453,3 €	68,1 / 100
Cluster 1	132	310,7 €	39,2 / 100




Figure 3 — Représentation des clusters K-Means (TJM vs. score de performance)

5.4 Comparaison avec l'étiquette Premium/Standard (a posteriori)

Bien que l'étiquette n'ait pas servi à construire les clusters, il est intéressant de comparer la répartition Premium/Standard au sein de chaque cluster, afin de vérifier si le clustering non supervisé retrouve une structure proche de la segmentation commerciale existante :

Cluster	Premium	Standard
Cluster 0	66	52

Cluster	Premium	Standard
Cluster 1	21	111

Le Cluster 0 (TJM et performance élevés) concentre une proportion nettement plus forte de profils Premium, ce qui confirme une cohérence encourageante entre la structure découverte de façon non supervisée et la segmentation commerciale historique de l'équipe.

5.5 Limites du modèle

- Le K-Means suppose des clusters de forme sphérique et de taille comparable, ce qui simplifie la réalité du marché du freelancing.
- Seules deux variables ont été utilisées (TJM, performance) ; des variables supplémentaires (ancienneté, domaine d'expertise, nombre de missions...) pourraient révéler une structure plus fine.
- Les quelques valeurs atypiques présentes dans le jeu de données peuvent influencer la position des centroïdes.

6. Question 4 — Classification supervisée (Régression logistique)

Auteur : Membre 7 — Analyste Data Science

6.1 Objectif et justification de la méthode

La fondatrice souhaite automatiser l'orientation commerciale : à l'inscription d'un nouveau freelance, prédire s'il doit être traité comme « Premium » ou « Standard », uniquement à partir du TJM déclaré et du score de performance historique.

La régression logistique a été retenue pour les raisons suivantes :

- Modèle probabiliste interprétable (probabilités et coefficients lisibles) ;
- Rapide à entraîner et à expliquer à une équipe non technique ;
- Cohérence avec les variables déjà utilisées dans les Questions 2 et 3 ;
- Permet une discussion fine des risques business (faux positifs vs. faux négatifs).

Prétraitement (cohérent avec le Membre 6) : standardisation des deux variables (moyenne 0, écart-type 1) avant l'entraînement, puis split train/test 75 % / 25 % stratifié afin de préserver la proportion des classes (environ 35 % Premium dans le jeu global).

6.2 Résultats numériques (graine = 853 155 114)

Indicateur	Valeur
Accuracy	73,02 %
Recall (classe Premium)	68,18 %

Matrice de confusion sur l'ensemble de test (n = 63) :

	Prédit Standard	Prédit Premium
Réel Standard	31	10
Réel Premium	7	15




Figure 4 — Matrice de confusion du modèle de régression logistique

Équation logistique (coefficients) :

$$\log\text{-odds}(\text{Premium}) = -0,8839 + 0,5677 \times \text{TJM} + 1,2040 \times \text{score_performance}$$

Les deux coefficients sont de signe positif : le TJM et la performance contribuent tous deux positivement à la probabilité d'être classé Premium.

6.3 Synthèse à destination de la fondatrice (risques business)

Avec une accuracy de 73 %, le modèle fait mieux qu'un classifieur naïf qui prédirait systématiquement « Standard » (classe majoritaire, ~65 %). La performance reste toutefois modérée, car la corrélation entre TJM/performance et le statut « au feeling » attribué par l'équipe commerciale n'est pas très forte (cf. Question 2).

Risques business identifiés

- Faux positifs (10 cas) : dilution de la marque Premium si des profils sur-valorisés sont orientés vers des clients exigeants sans vérification.
- Faux négatifs (7 cas) : opportunités ratées — bons profils sous-classés, risque de départ vers la concurrence.

6.4 Recommandation opérationnelle

- Probabilité prédite > 0,65 → proposition Premium + revue rapide par l'équipe commerciale.
- Probabilité prédite < 0,35 → Standard par défaut.
- Zone grise (0,35 – 0,65) → examen humain obligatoire.

6.5 Analyse critique et limites

- Le statut Premium/Standard a été attribué « au feeling » par l'équipe commerciale : le modèle apprend donc des biais et intuitions passées plutôt qu'une vérité objective.

- Seules deux variables sont disponibles ; l'ajout de variables métier (domaine d'expertise, ancienneté, taux de complétion, notes clients...) améliorerait la discrimination.
- La régression logistique suppose une relation linéaire dans l'espace logit ; des modèles non linéaires (Random Forest, Gradient Boosting) pourraient capturer des interactions plus fines, au prix d'une moindre interprétabilité.
- L'échantillon est synthétique et déterministe : un test sur des données opérationnelles réelles reste indispensable avant tout déploiement.

Conclusion : le modèle constitue un outil d'aide à la décision raisonnable, mais insuffisant pour une automatisation aveugle sans supervision humaine sur les cas limites.

Conclusion générale

Les quatre analyses menées sur le jeu de données synthétique du Groupe 14 dressent un portrait cohérent de la plateforme de freelances : la base de talents est globalement solide (Question 1), mais le TJM seul explique très peu la performance réelle des prestataires (Question 2, $R^2 = 7,68 \%$). Le clustering non supervisé (Question 3) retrouve néanmoins une structure à deux groupes cohérente avec la segmentation Premium/Standard existante, et le modèle de classification (Question 4) atteint une accuracy de 73 %, suffisante pour servir d'aide à la décision mais insuffisante pour une automatisation totale.

Dans l'ensemble, les résultats invitent à la prudence : les décisions commerciales et d'investissement ne devraient pas reposer sur un unique indicateur tarifaire, mais s'appuyer sur une combinaison de signaux (performance historique, régularité des missions, domaine d'expertise) couplée à une supervision humaine sur les cas ambigus. Le caractère synthétique et déterministe du jeu de données invite par ailleurs à valider ces conclusions sur des données opérationnelles réelles avant tout déploiement à grande échelle.